

LAPORAN TEKNIS DATA SCIENCE

BAB I

PENDAHULUAN

A. Latar Belakang

Permasalahan sampah di Indonesia terus meningkat seiring dengan pertumbuhan konsumsi masyarakat yang tidak diimbangi dengan sistem pengelolaan yang optimal. Akar masalah utama adalah kurangnya pemilahan sampah sejak dari sumbernya, sehingga sampah organik dan anorganik sering tercampur dan mempersulit proses daur ulang. Kondisi ini terutama terjadi di lingkungan rumah tangga, disebabkan oleh rendahnya pemahaman masyarakat serta minimnya alat bantu pemilahan yang praktis.

Melalui proyek Sortir.in, tim mengembangkan aplikasi web berbasis kecerdasan buatan yang memungkinkan pengguna mengidentifikasi jenis sampah melalui gambar, dilengkapi dengan fitur tukar poin sebagai mekanisme insentif untuk mendorong perilaku pemilahan sampah. Peran tim Data Science dalam proyek ini adalah menyediakan data yang bersih dan siap pakai untuk model AI, menghasilkan insight dari analisis data, serta melakukan validasi statistik terhadap performa model.

B. Pertanyaan Bisnis

Berdasarkan data sampah nasional yang tersedia, tim Data Science merumuskan dua pertanyaan bisnis sebagai berikut.

1. Seberapa besar proporsi sampah yang belum terkelola di Indonesia dan daerah mana yang paling kritis, sehingga memperkuat urgensi pengembangan fitur deteksi sampah berbasis AI pada aplikasi Sortir.in?
2. Apakah daerah dengan volume timbulan sampah tinggi justru memiliki tingkat pengelolaan yang rendah, dan bagaimana pola ini mendukung pentingnya mekanisme insentif seperti fitur tukar poin untuk mendorong perilaku pemilahan sampah di masyarakat?

C. Tujuan

Laporan ini bertujuan untuk mendokumentasikan seluruh proses kerja tim Data Science, mulai dari pengumpulan dan pembersihan data, analisis eksploratif, hingga validasi statistik performa model. Secara spesifik, tujuan laporan ini adalah sebagai berikut.

1. Mendokumentasikan proses data wrangling dan EDA pada dataset gambar sampah sebagai bahan pelatihan model AI.

2. Menyajikan analisis dan insight dari data tabular sampah nasional sebagai landasan dashboard Streamlit dan justifikasi produk Sortir.in.
3. Memaparkan hasil A/B Testing sebagai validasi statistik terhadap performa dua versi model klasifikasi.

BAB II

HASIL DAN PEMBAHASAN

A. Data Gambar Sampah

Dataset gambar sampah merupakan dataset yang digunakan untuk modeling AI untuk klasifikasi sampah

1. Sumber Data

Dataset gambar yang digunakan bersumber dari Kaggle dengan nama dataset sampah-daur-ulang . Dataset diunduh mealui kaggle dan terdiri dari gambar sampah yang terbagi ke dalam 6 kategori: Kaca, Kardus, Kertas, Logam, Plastik, dan Residu.

2. Data Wrangling

Proses data wrangling dilakukan secara end-to-end mencakup tiga tahap utama. Gathering. Seluruh file gambar dari 6 folder kategori dipindai dan diorganisir ke dalam sebuah DataFrame metadata yang memuat informasi path, filename, label, dan ekstensi setiap gambar.

Assessing. Tiga jenis pemeriksaan dilakukan:

- a. validasi ekstensi file hanya file dengan ekstensi .jpg, .jpeg, .png, .bmp, dan .webp yang dipertahankan;
- b. deteksi gambar corrupt
- c. deteksi duplikat dua tahap, yakni berdasarkan nama file dan berdasarkan hash konten file menggunakan algoritma MD5.

Cleaning. Berdasarkan hasil assessing, file dengan ekstensi tidak valid, gambar corrupt, dan duplikat dihapus dari dataset. Dataset final yang bersih kemudian disiapkan untuk tahap analisis dan pemodelan.

3. Exploratory Data Analysis

Analisis eksploratif pada dataset gambar difokuskan pada dua pertanyaan bisnis yang relevan dengan kebutuhan pengembangan model AI. Distribusi kelas. Hasil analisis

menunjukkan bahwa Kertas adalah kategori dengan jumlah gambar terbanyak (1.987 gambar), diikuti Plastik (1.254), Logam (1.209), Kaca (1.111), Residu (980), dan Kardus (699). Rasio kelas terbanyak terhadap tersedikit adalah 2,84x, di bawah ambang batas 3x, sehingga distribusi kelas dinyatakan relatif seimbang dan tidak memerlukan oversampling khusus.

Analisis dimensi dan resolusi. Hampir seluruh gambar pada dataset memiliki resolusi di bawah standar 224x224 piksel yang umum digunakan dalam model deep learning, terutama pada kategori Logam dan Kaca. Kondisi ini mengharuskan adanya preprocessing upscaling sebelum pelatihan model.

Analisis variasi fitur. Kategori Residu menunjukkan variasi warna (standar deviasi RGB) dan variasi bentuk (standar deviasi width, height, aspect ratio) tertinggi dibandingkan kategori lain. Hal ini sesuai dengan sifat residu yang mencakup berbagai jenis sampah tidak terklasifikasi. Kategori ini memerlukan strategi augmentasi data yang lebih intensif.

Analisis pencahayaan. Kategori Residu juga memiliki persentase gambar dengan pencahayaan ekstrem tertinggi (sekitar 32%), didefinisikan sebagai gambar dengan nilai brightness di luar rentang persentil ke-5 dan ke-95 dari distribusi keseluruhan.

4. Persiapan Dataset untuk Model AI

Dataset final dibagi menggunakan stratified split dengan proporsi Train 70%, Validasi 10%, dan Test 20%, menggunakan parameter stratify=label dan random_state=42 untuk menjamin reproducibility dan distribusi kelas yang proporsional di setiap subset.

B. DATA TABULAR

Data tabular yang digunakan untuk mendukung dashboard Streamlit bersumber dari open data kementerian lingkungan hidup dengan jumlah 514 raw. Dataset ini memuat informasi volume timbulan sampah, jenis Tempat Pembuangan Akhir (TPA), dan persentase pengelolaan sampah di tingkat kabupaten/kota seluruh Indonesia. Data diambil dengan melakukan scraping.

1. Data Wrangling

Proses pembersihan data mencakup penghapusan spasi berlebih pada nama kolom, pengisian missing value pada kolom Jenis TPA dengan nilai 'Tidak Diketahui', pembersihan kolom Timbulan dengan menghapus satuan tpd dan mengkonversi ke numerik, serta pembersihan kolom persentase dengan mengganti koma menjadi titik dan

menghapus simbol persen. Kolom yang tidak relevan untuk analisis (No, waktu_scraping, Progress SA) dihapus dari dataset.

2. Exploratory Data Analysis

Analisis eksploratif pada data tabular dirancang untuk menjawab dua pertanyaan bisnis yang menjadi landasan produk Sortir.in.

Pertanyaan Bisnis 1 Proporsi sampah belum terkelola dan daerah kritis. Analisis rata-rata nasional menunjukkan bahwa masih terdapat proporsi sampah yang belum terkelola secara signifikan di Indonesia. Visualisasi peta choropleth tingkat provinsi menggunakan GeoPandas menampilkan distribusi spasial persentase sampah belum terkelola, mengidentifikasi provinsi-provinsi yang paling membutuhkan intervensi. Temuan ini menjadi justifikasi kuat urgensi fitur deteksi sampah berbasis AI pada Sortir.in, karena masalah pengelolaan sampah masih sangat nyata dan merata di seluruh wilayah Indonesia.

Pertanyaan Bisnis 2 Hubungan timbunan tinggi dengan pengelolaan rendah. Visualisasi scatter plot antara volume timbunan (tpd) dan persentase sampah belum terkelola, dikombinasikan dengan heatmap korelasi, mengungkap pola hubungan antar variabel. Peta persebaran timbunan sampah nasional per provinsi melengkapi analisis ini dengan perspektif geografis. Temuan bahwa daerah dengan produksi sampah tinggi tidak selalu memiliki kapasitas pengelolaan yang memadai memperkuat argument perlunya mekanisme insentif seperti fitur tukar poin pada Sortir.in untuk mendorong partisipasi aktif masyarakat dalam pemilahan sampah..

Selain menjawab kedua pertanyaan bisnis tersebut, analisis juga mencakup distribusi jenis TPA di seluruh Indonesia untuk memberikan gambaran kondisi infrastruktur pengelolaan sampah secara umum.

3. Data Dictionary

Kolom	Tipe Data	Deskripsi
Provinsi	string	Nama provinsi di Indonesia
Kota/Kabupaten	string	Nama kota atau kabupaten
Timbunan	float (tpd)	Volume timbunan sampah dalam ton per hari
Jenis TPA	string	Jenis TPA; missing value diisi 'Tidak Diketahui'
% S. Terkelola	float (%)	Persentase sampah yang berhasil dikelola

% S. Belum Terkelola	float (%)	Persentase sampah yang belum terkelola
----------------------	-----------	--

C. A/B TESTING

A/B Testing adalah metode eksperimen yang digunakan untuk membandingkan dua versi (A dan B) dari suatu produk, sistem, atau model guna menentukan mana yang memberikan kinerja lebih baik berdasarkan metrik tertentu.

1. Latar Belakang

Setelah tim AI Engineer menghasilkan model klasifikasi gambar sampah, tim Data Science melakukan validasi statistik menggunakan A/B Testing untuk menentukan apakah perbedaan akurasi antara Model A dan Model B signifikan secara statistik atau hanya terjadi secara kebetulan. Hasil pengujian ini menjadi dasar rekomendasi model mana yang sebaiknya digunakan pada aplikasi Sortir.in.

2. Design Eksperimen

Komponen	Keterangan
Metode	Two-sample Z-test untuk dua proporsi (uji dua sisi)
Metrik	Akurasi klasifikasi (proporsi prediksi benar)
Data	hasil inferensi kedua model pada data test yang sama
H_0	Tidak ada perbedaan akurasi antara Model A dan Model B ($p_A = p_B$)
H_1	Ada perbedaan akurasi yang signifikan antara Model A dan Model B ($p_A \neq p_B$)
Tingkat signifikansi (α)	0,05


3. Metode

Untuk setiap model dihitung tiga metrik dasar: n (total sampel), x (jumlah prediksi benar), dan p (proporsi/akurasi). Proporsi gabungan (pooled proportion) dihitung sebagai estimasi proporsi di bawah asumsi H_0 . Z-statistic kemudian dihitung dengan membagi selisih proporsi dengan standar error gabungan. P-value diperoleh dari distribusi normal standar dengan pendekatan two-tailed test.

Selain uji statistik keseluruhan, analisis per kelas juga dilakukan untuk mengidentifikasi kategori sampah mana yang mengalami peningkatan atau penurunan

akurasi antara kedua model. Confidence interval 95% untuk selisih proporsi turut dihitung untuk memberikan estimasi rentang perbedaan akurasi yang dapat dipercaya.

4. Hasil dan Interpretasi



Dapat terlihat pada grafik batang paling kiri, akurasi untuk model A lebih tinggi dari model B dengan beda sebesar 4,7%. Hal ini menginterpretasikan adanya perbedaan akurasi yang signifikan antara Model A dan Model B. Perbedaan signifikan tersebut dapat dijawab jika melihat grafik batang yang menginterpretasikan akurasi per kelas, yang dimana Model A ternyata memiliki akurasi yang baik terhadap 4 kelas, sedangkan untuk 2 kelas lainnya yaitu plastik dan residu memiliki akurasi dibawah model B.

Sebagaimana syarat untuk menolak H_0 , diperlukan nilai p-value yang nilainya harus lebih kecil dari signifikansi yang sudah kita tentukan sebelumnya yaitu 0,05. Hasil p-value yang berhasil dihitung nilainya adalah 0,0351 yang mana nilai tersebut lebih kecil dari nilai signifikansi kita. Ini berarti ada cukup data untuk membuktikan bahwa kita dapat menolak H_0 .

BAB III

KESIMPULAN

Berdasarkan hasil pengolahan dan analisis data pada proyek Sortir.in, dataset gambar sampah daur ulang telah siap digunakan setelah dibersihkan dari *file* korup, duplikat, dan ekstensi tidak valid. Meskipun distribusi antar kelas sudah relatif seimbang (rasio 2,84x), penerapan teknik *upscaling* dan *data augmentation* mutlak diperlukan untuk mengatasi dominasi resolusi rendah dan variasi ekstrem pada kategori Residu. Kesiapan data ini sejalan dengan analisis data pengelolaan sampah nasional dari 514 kabupaten/kota yang mengonfirmasi urgensi proyek. Tingginya volume timbulan sampah yang tidak berbanding lurus dengan tingkat pengelolaannya membuktikan minimnya kesadaran warga dalam memilah sampah. Fakta operasional ini menjadi landasan kuat bahwa fitur deteksi AI yang praktis serta mekanisme insentif "Tukar Poin" pada aplikasi Sortir.in sangat krusial untuk diimplementasikan demi mengubah perilaku masyarakat.

Untuk menentukan kelayakan sistem, validasi statistik melalui *A/B Testing* dengan *Two-sample Z-test* telah dilakukan guna membandingkan performa dua kandidat model AI. Hasil pengujian membuktikan bahwa Model A jauh lebih unggul dengan selisih akurasi keseluruhan sebesar 4,7% di atas Model B. Keunggulan tersebut terbukti signifikan secara statistik melalui perolehan *p-value* sebesar 0,0351, yang berada di bawah ambang batas signifikansi ($\alpha = 0,05$), sehingga secara meyakinkan menolak Hipotesis Nol (H_0). Dengan kemampuan generalisasi klasifikasi yang lebih merata di mayoritas kategori sampah, tim merekomendasikan Model A sebagai model final yang siap diintegrasikan ke dalam lingkungan produksi aplikasi Sortir.in.